

GOAI 2026 Generalization 冒烟测试报告

1. 测试目的与边界

本测试用于确认 step-199999 checkpoint 在 RoboDojo Generalization 全部 24 个配置上的 端到端链路：模型加载、三视角观测、策略推理、EE 动作解码、Isaac Sim 执行以及结果文件 落盘。测试不是正式榜单评测，也不是具有统计显著性的性能评估。

- checkpoint: HyVLA-GOAI-step-199999
- action type: ee
- dimension: generalization
- seed: 原始全量矩阵为 0；pour_liquid_into_cup 补充 1/2
- episode: 每配置 1 个，共 24 个
- 配置: 12 个标准配置 + 12 个 _random 配置
- policy: Hy_Embodied_05_VLA
- policy GPU / environment GPU: 同一张 RTX 4090
- eval_batch: false

2. 两类“通过”必须区分

runner status=PASS 表示该配置完成评测并生成合法 _result.json。success=true 才表示 该 episode 达到任务二元成功条件。本次 24 个配置全部完成；按“每个配置是否曾在有效 seed 测试中观察到成功”的展示口径，共有 3 个配置成功覆盖。

指标	全部	标准配置	Random 配置
配置数	24	12	12
runner PASS	24	12	12
二元成功覆盖	3	3	0
二元成功覆盖率	12.50%	25.00%	0%
原始 seed 0 score 简单平均	11.67	21.25	2.08

成功覆盖任务为 fold_clothes (seed 0)、stack_bowls (seed 0) 和 pour_liquid_into_cup (补充 seed 1)。因此本报告对外展示的冒烟成功率为 3/24。

3. 逐配置结果

配置	Runner	Success	Score	墙钟时间 (秒)
arrange_largest_number	PASS	0	5	494
arrange_largest_number_random	PASS	0	0	592
fold_clothes	PASS	1	100	315
fold_clothes_random	PASS	0	0	526
hang_mugs	PASS	0	0	438
hang_mugs_random	PASS	0	0	596
make_toast	PASS	0	0	671
make_toast_random	PASS	0	0	694
pack_objects_into_box	PASS	0	50	577
pack_objects_into_box_random	PASS	0	25	681
pour_liquid_into_cup	PASS	0	0	364
pour_liquid_into_cup_random	PASS	0	0	477
push_T	PASS	0	0	374
push_T_random	PASS	0	0	395
sort_nesting_dolls_by_size	PASS	0	0	517
sort_nesting_dolls_by_size_random	PASS	0	0	563
stack_blocks	PASS	0	0	358
stack_blocks_random	PASS	0	0	416
stack_bowls	PASS	1	100	312
stack_bowls_random	PASS	0	0	482
store_laptop_and_headphones	PASS	0	0	488
store_laptop_and_headphones_random	PASS	0	0	430
sweep_blocks	PASS	0	0	489
sweep_blocks_random	PASS	0	0	517

24 项墙钟时间合计约 3 小时 16 分。该时间包含每个配置重新启动 policy server、加载约 45 亿参数模型和启动 Isaac Sim 的开销，不能当作单个 episode 的纯执行时延。

4. 观察与风险

1. `fold_clothes`、`stack_bowls` 和 `pour_liquid_into_cup` 三个标准配置均观察到成功；前两项为原始 seed 0，第三项为补充 seed 1。
2. `arrange_largest_number`、`pack_objects_into_box` 及其 random 配置出现部分得分，说明任务有阶段性进展，但未达到二元成功条件。
3. 12 个 random 配置本次均未二元成功，提示泛化能力仍有待提升。
4. 每配置只有 1 个 episode，任何百分比都具有很高方差，不能外推为正式成功率。
5. 线上仿真最终计分不是只看二元成功率；依据参赛手册，还会综合任务完成质量和执行效果。

机器可读明细见 `results/metrics/evaluation_results.csv`。

5. `pour_liquid_into_cup` 三 seed 补充实验

完成原始24配置冒烟后，对标准配置 `pour_liquid_into_cup` 补充了赛事资源实际提供的全部三个布局 seed。RoboDojo 的 `Assets/Eval_Layout/RoboDojo/arx_x5/` 仅包含 0/1/2；seed 3 没有布局目录，因此其启动失败不计为有效 episode。

Seed	Runner	Success	Score	来源
0	PASS	0	0	原始24配置冒烟
1	PASS	1	100	补充实验
2	PASS	0	0	补充实验

该任务在 seed 0/1/2 上的二元成功率为 $1/3 = 33.33\%$ ，平均分为 33.33。按本报告采用的“每个配置是否曾观察到成功”展示口径，该成功计入总体成功覆盖，因此报告值为 3/24。该值包含跨 seed 结果，不等同于固定 seed 0 的均匀矩阵估计，也不代表正式评测成功率。

机器可读结果见 `results/metrics/pour_liquid_3seed_results.csv`。

6. `pack_objects_into_box` 标准与 random 三 seed 补充实验

对 `pack_objects_into_box` 和 `pack_objects_into_box_random` 分别补充 seed 1/2，并与原始 seed 0 合并。六个 episode 均正常生成结果文件。

配置	Seed 0	Seed 1	Seed 2	三 seed 二元成功率	平均分
<code>pack_objects_into_box</code>	50	0	25	0/3 (0%)	25.00

配置	Seed 0	Seed 1	Seed 2	三 seed 二元成功率	平均分
pack_objects_into_box_random	25	0	25	0/3 (0%)	16.67

两个配置在不同 seed 下都出现过部分完成，但尚未观察到二元成功，因此不改变本报告的 3/24 成功覆盖统计。机器可读结果见 results/metrics/pack_objects_into_box_3seed_results.csv。

源文件：docs/冒烟测试报告.md